

# تکلیف اول درس شبکه‌های عصبی

وحید ملکی

شماره دانشجویی: ۴۰۳۱۳۰۰۴

۲۶ آبان ۱۴۰۴

## سوال ۴

### الف: محو شدن و انفجار گرادیان چیست؟

در آموزش شبکه‌های عصبی عمیق، گرادیان تابع هزینه نسبت به وزن‌های لایه‌های اولیه با استفاده از قاعده زنجیره‌ای و به صورت ضرب مکرر مشتق توابع فعال‌سازی و وزن‌های لایه‌های بعدی محاسبه می‌شود.

• محو شدن گرادیان (Vanishing Gradient): زمانی رخ می‌دهد که مقادیر مطلق مشتق توابع فعال‌سازی (مانند Sigmoid و Tanh) در نواحی اشباع کمتر از ۱ باشد. با افزایش تعداد لایه‌ها، ضرب مکرر اعداد کوچکتر از ۱ باعث می‌شود گرادیان در لایه‌های ابتدایی به صورت نمایی به صفر نزدیک شود. نتیجه عملی: لایه‌های اولیه تقریباً هیچ به‌روزرسانی دریافت نمی‌کنند، ویژگی‌های سطح پایین (مانند لبه‌ها و گوشه‌ها در بینایی ماشین) به خوبی یاد گرفته نمی‌شوند و کل شبکه عملاً به یک شبکه کم‌عمق تبدیل می‌شود.

• انفجار گرادیان (Exploding Gradient): زمانی رخ می‌دهد که مقادیر مطلق مشتق‌ها یا وزن‌ها بزرگتر از ۱ باشند. ضرب مکرر این اعداد باعث رشد نمایی گرادیان می‌شود و مقدار آن به سرعت به اعداد بسیار بزرگ یا حتی NaN تبدیل می‌شود. نتیجه عملی: وزن‌ها تغییرات بسیار شدیدی می‌کنند، تابع هزینه نوسانات شدید پیدا می‌کند و آموزش کاملاً ناپایدار می‌شود.

### ب: روش کلاسیک و بسیار موفق — نرمال‌سازی دسته‌ای (Batch Normalization)

Batch Normalization که در سال ۲۰۱۵ توسط Sergey Ioffe و Christian Szegedy معرفی شد، تا چند سال استاندارد طلایی برای حل این دو مشکل بود. فرمول کامل BatchNorm در زمان آموزش:

$$\mu_B = \frac{1}{m} \sum_{i=1}^m x_i, \quad \sigma_B^2 = \frac{1}{m} \sum_{i=1}^m (x_i - \mu_B)^2$$

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}, \quad y_i = \gamma \hat{x}_i + \beta$$

که  $\gamma$  و  $\beta$  پارامترهای قابل یادگیری هستند و در زمان استنتاج از میانگین و واریانس متحرک استفاده می‌شود. چرا BatchNorm این مشکلات را حل می‌کند؟

- توزیع ورودی هر لایه را به میانگین صفر و واریانس یک می‌رساند  $\Rightarrow$  از ورود به نواحی اشباع توابع فعال‌سازی جلوگیری می‌کند.
- گرادیان‌ها را در مقیاس مناسب نگه می‌دارد  $\Rightarrow$  هم از محو شدن و هم از انفجار جلوگیری می‌کند.
- اجازه استفاده از نرخ یادگیری بسیار بالاتر را می‌دهد.
- اثر منظم‌سازی دارد و نیاز به Dropout را کاهش می‌دهد.

### معایب مهم BatchNorm:

- وابستگی شدید به ساینج (در Batch Size کوچک، تخمین  $\mu$  و  $\sigma$  نویزدار می‌شود)
- افزایش مصرف حافظه (نیاز به ذخیره آماربج)
- مشکل در شبکه‌های بازگشتی و آموزش آنلاین
- تفاوت رفتار بین آموزش و استنتاج

## ج: مقاله علمی پیشنهادی — حذف کامل نرمال‌سازی با روشی هوشمندانه

عنوان مقاله: High-Performance Large-Scale Image Recognition Without Normalization

نویسندگان: Samuel L. Smith, Soham De, Andrew Brock (همه از DeepMind)

کنفرانس/سال: ICML 2021

لینک کامل: <https://arxiv.org/abs/2102.06171>

این مقاله یکی از مهم‌ترین مقالات سال ۲۰۲۱ در حوزه پایداری آموزش شبکه‌های عمیق است و نشان می‌دهد که نه تنها می‌توان BatchNorm را حذف کرد، بلکه با حذف آن می‌توان به عملکرد بهتری هم رسید!

## ایده اصلی مقاله: شبکه‌های بدون نرمال‌سازی (Normalizer-Free Nets یا NFNet)

نویسندگان مشاهده کردند که BatchNorm در واقع دو نقش دارد: ۱. پایدار کردن آموزش (جلوگیری از Vanishing/Exploding Gradient) ۲. منظم‌سازی. آنها نشان دادند که نقش اول را می‌توان با روشی بسیار ساده‌تر و کارآمدتر جایگزین کرد: برش تطبیقی گرادیان (Adaptive Gradient Clipping — AGC)

## توضیح کامل روش Adaptive Gradient Clipping (AGC)

روش کلاسیک Gradient Clipping یک آستانه ثابت (مثلاً ۰.۱) روی نرم گرادیان کل شبکه اعمال می‌کند. اما AGC هوشمندانه‌تر عمل می‌کند:

برای هر پارامتر  $w$  در هر لایه، نسبت نرم گرادیان به نرم وزن محاسبه می‌شود:

$$r = \frac{\|\nabla_w \mathcal{L}\|_2}{\|w\|_2 + \epsilon}$$

اگر این نسبت از یک آستانه  $\lambda$  بیشتر باشد، گرادیان آن لایه به صورت زیر کوچک می‌شود:

$$\nabla_w \mathcal{L} \leftarrow \nabla_w \mathcal{L} \times \min\left(1, \frac{\lambda}{r}\right)$$

به عبارت ساده تر: «تغییر وزن در هر قدم نباید بیشتر از  $\lambda$  برابر مقدار فعلی وزن باشد.»  
این کار باعث می شود: - وزن ها هرگز تغییرات بسیار شدید نداشته باشند  $\Rightarrow$  انفجار گرادیان غیرممکن می شود. -  
در عین حال گرادیان های مفید و معقول حفظ می شوند (برخلاف برش ثابت که ممکن است گرادیان های بزرگ اما مفید را هم قطع کند).

## نتایج شگفت انگیز مقاله

- مدل NFNet-F6 بدون هیچ نوع نرمال سازی (نه BatchNorm، نه LayerNorm، نه GroupNorm) به دقت 88.5% Top-1 در ImageNet رسید که در زمان انتشار رکورد جدیدی بود.
- آموزش پایدار حتی با  $\text{Batch Size} = 16$  یا کمتر.
- سرعت آموزش تا ۸۰٪ بالاتر از مدل های معادل با BatchNorm.
- مصرف حافظه به شدت کاهش یافت.
- شبکه های تا بیش از ۱۰۰۰ لایه بدون مشکل آموزش داده شدند.

## مزایای روش AGC و NFNet

- حذف کامل تمام لایه های نرمال سازی  $\Rightarrow$  کد ساده تر، سرعت بالاتر، حافظه کمتر
- کاملاً مستقل از سلیز بچ  $\Rightarrow$  ایده آل برای آموزش توزیع شده و دستگاه های با حافظه محدود
- امکان استفاده از نرخ یادگیری بسیار بالا
- جلوگیری همزمان و مؤثر از هر دو مشکل Vanishing و Exploding Gradient
- دستیابی به دقت State-of-the-Art بدون هیچ ترفند اضافی
- قابل تعمیم به معماری های دیگر (بعداً روی Transformer ها و ViT ها هم موفق بوده)

## محدودیت ها و نکات عملی

- نیاز به تنظیم دقیق  $\lambda$  (معمولاً بین ۰.۰۱ تا ۰.۱ بسته به معماری)
- محاسبه نرم وزن در هر لایه هزینه محاسباتی جزئی اضافه می کند (ولی بسیار کمتر از BatchNorm)
- در مقاله اصلی فقط روی شبکه های کانولوشنی تست شده بود (هرچند مقالات بعدی نشان دادند روی Transformer ها هم عالی کار می کند)

## جمع بندی نهایی

مشکلات Vanishing و Exploding Gradient از مهم ترین موانع آموزش شبکه های عمیق بودند که با Batch Normalization تا حد زیادی حل شدند. اما مقاله ICML 2021 از DeepMind با معرفی Adaptive Gradient Clipping نشان داد که می توان بدون هیچ نوع نرمال سازی و فقط با یک خط کد ساده، شبکه های عمیق تر، سریع تر و دقیق تر ساخت. این روش امروزه یکی از قدرتمندترین و مدرن ترین تکنیک های پایدارسازی آموزش شبکه های عصبی عمیق محسوب می شود و به سرعت در جامعه تحقیقاتی و صنعتی در حال گسترش است.