

تکلیف دوم درس شبکه های عصبی

وحید ملکی، پوریا دادستان

۱۵ آذر ۱۴۰۴

سوال ۵: پیش بینی فعال سازی هشدار آتش سوزی با شبکه عصبی MLP

۱. مقدمه و پیش پردازش داده ها

در این پروژه، هدف طراحی یک مدل شبکه عصبی برای پیش بینی وضعیت هشدار آتش سوزی در خانه های هوشمند بر اساس داده های سنسورهای محیطی است. مجموعه داده شامل حدود ۷۰,۰۰۰ نمونه با ویژگی های مختلف (دما، رطوبت، غلظت گازها و ...) است.

۱-۱. مدیریت مقادیر گمشده (Missing Values)

پس از بارگذاری داده ها، مشخص شد که حدود 162,747 مقدار گمشده در دیتاست وجود دارد. برای مدیریت این مقادیر از روش های زیر استفاده شد:

- ویژگی های عددی: از میانه (Median) استفاده شد، زیرا نسبت به میانگین در برابر داده های پرت مقاوم تر است.

- ویژگی های دسته بندی: از مد (Mode) یا پرتکرارترین مقدار استفاده شد.

۲-۱. کدگذاری ویژگی های گسسته (Encoding)

ویژگی های غیر عددی مانند جهت وزش باد (RedLightDir، SteamDir) با استفاده از روش Label Encoding به اعداد تبدیل شدند. متغیر هدف (FireAlarm) نیز به صورت دودویی (0 برای خیر و 1 برای بله) کدگذاری شد.




شکل ۱: توزیع متغیر هدف (FireAlarm). مشاهده می‌شود که عدم توازن کلاس مشهود است (تعداد نمونه‌های "خیر" بسیار بیشتر از "بله" است).

۳-۱. شناسایی داده‌های پرت و نرمال‌سازی


برای شناسایی داده‌های پرت از روش امتیاز استاندارد (Z-Score) با آستانه 3 استفاده شد. در نتیجه، حدود 4335 نمونه پرت حذف گردید و تعداد نمونه‌ها به 65,664 رسید. سپس داده‌ها با استفاده از Standard Scaler نرمال‌سازی شدند تا میانگین هر ویژگی صفر و انحراف معیار آن یک شود. این کار برای همگرایی سریع‌تر گرادیان نزولی حیاتی است.

۰۲. بررسی تفکیک‌پذیری خطی (شبکه پرسپترون)

یک شبکه پرسپترون تک لایه (Single Layer Perceptron) طراحی شد تا خطی بودن داده‌ها بررسی شود. نتایج نشان داد که دقت کلی مدل حدود 84.79% است، اما در شناسایی کلاس اقلیت (آتش‌سوزی) ضعیف عمل می‌کند (Recall برابر 0.44). این نشان می‌دهد که داده‌ها به طور کامل خطی جدایی‌پذیر نیستند و برای دستیابی به عملکرد بهتر، به مدل‌های پیچیده‌تر و غیرخطی نیاز است.



(ب) ماتریس درهم‌ریختگی پرسپترون



(آ) منحنی خطای آموزش و آزمون پرسپترون

شکل ۲: نتایج ارزیابی مدل خطی پرسپترون

۳. طراحی و بهینه‌سازی شبکه عصبی چندلایه (MLP)

با توجه به عدم توازن شدید کلاس‌ها (تعداد نمونه‌های سالم حدود ۴ برابر نمونه‌های آتش‌سوزی)، از تکنیک وزن‌دهی به تابع هزینه (Weighted Loss) استفاده شد. وزن کلاس مثبت حدود 3.88 محاسبه گردید تا مدل تنبیه بیشتری برای عدم تشخیص آتش‌سوزی دریافت کند.


۳-۱. معماری شبکه پیشنهادی

پس از آزمایش‌های متعدد، معماری زیر انتخاب شد:

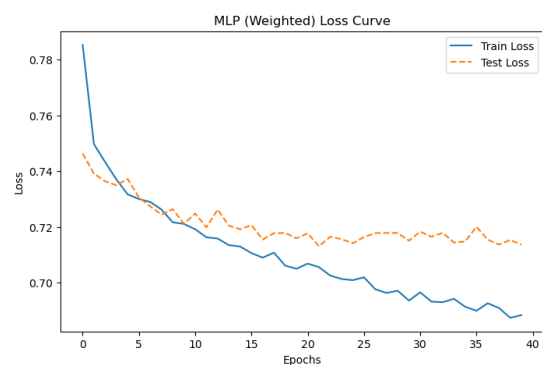
- لایه ورودی: ۲۰ نورون (متناظر با ویژگی‌ها)
- لایه مخفی ۱: ۶۴ نورون با تابع فعال‌ساز ReLU و لایه Dropout با نرخ 0.2
- لایه مخفی ۲: ۳۲ نورون با تابع فعال‌ساز ReLU
- لایه خروجی: ۱ نورون (پیش‌بینی باینری)

۳-۲. تحلیل نتایج نهایی

مدل MLP بهینه شده توانست به دقت کلی 79.87% دست یابد. نکته حائز اهمیت، افزایش چشمگیر نرخ فراخوانی (Recall) برای کلاس آتش‌سوزی به 0.78 است (در مقایسه با 0.44 در پرسپترون). این یعنی مدل توانسته است اکثر موارد واقعی آتش‌سوزی را شناسایی کند، هرچند به قیمت کاهش اندکی در دقت کلی (افزایش هشدارهای کاذب). در سیستم‌های ایمنی، شناسایی خطر اولویت بالاتری نسبت به دقت کلی دارد.



(ب) ماتریس درهم‌ریختگی مدل MLP



(آ) منحنی خطای مدل MLP

شکل ۳: نتایج نهایی شبکه عصبی بهینه شده با تابع هزینه وزن‌دار

۴. نتیجه‌گیری

این پروژه نشان داد که:

۱. پیش‌پردازش دقیق (حذف داده‌های پرت و نرمال‌سازی) تأثیر بسزایی در پایداری آموزش دارد.
۲. داده‌های این مسئله به طور کامل خطی جدایی‌پذیر نیستند.

۳. استفاده از شبکه عصبی عمیق تر همراه با استراتژی مدیریت عدم توازن (مانند Weighted BCE Loss) باعث بهبود قابل توجه در شناسایی رخدادهای حساس (آتش سوزی) می شود.